

Guía del examen final

Esta guía orienta el estudio para el examen final (sesión 8). Las preguntas buscan orientar el estudio **conceptual**: en el examen se evaluará principalmente la capacidad de **interpretar resultados, analizar escenarios y tomar decisiones** con base en estos conceptos, no la memorización de sintaxis de Python.

1. Preparación de datos (notebooks 03-04)

- 1.1 ¿Cuál es el propósito principal de las librerías Pandas, NumPy y Matplotlib en análisis de datos?
- 1.2 ¿En qué condiciones generalmente es aceptable eliminar filas con datos perdidos?
- 1.3 ¿Por qué no es recomendable eliminar filas con datos perdidos en una serie de tiempo?
- 1.4 ¿En qué casos es apropiado identificar datos atípicos utilizando el método de valores z?
- 1.5 ¿Cuándo es preferible utilizar el rango intercuartil (IQR) para detectar datos atípicos?
- 1.6 ¿En qué situaciones es recomendable identificar datos atípicos mediante el algoritmo Isolation Forest?
- 1.7 ¿Cuáles son las principales estrategias para tratar datos atípicos y en qué casos se recomienda aplicar cada una?
- 1.8 ¿Cuándo eliminar un outlier puede ser un error conceptual?
- 1.9 ¿Qué diferencia hay entre imputar con la media versus la mediana?

2. Análisis descriptivo (notebooks 05-06)

- 2.1 ¿En qué situaciones es preferible utilizar la mediana en lugar de la media como medida de tendencia central?
- 2.2 ¿Qué se puede inferir sobre la distribución de los datos a partir de la relación entre la media y la mediana?
- 2.3 ¿Cuál es la relación matemática entre la varianza y la desviación estándar?
- 2.4 ¿Qué mide el coeficiente de asimetría y cómo se interpreta?
- 2.5 ¿Qué mide la curtosis y qué información aporta sobre la distribución de los datos?
- 2.6 ¿Cuáles son las principales diferencias entre un diagrama de barras y un histograma, y en qué contextos se recomienda cada uno?

3. Fundamentos de inferencia (notebook 07)

- 3.1 ¿Qué establece el Teorema del Límite Central y por qué es la base de muchas pruebas estadísticas?
- 3.2 ¿Qué es el p-valor y qué **no** es?
- 3.3 ¿Por qué "no rechazar la hipótesis nula" no equivale a "aceptar que es verdadera"?

4. Evaluación de supuestos (notebook 08)

- 4.1 Menciona al menos tres pruebas estadísticas utilizadas para evaluar la normalidad de los datos.
- 4.2 ¿Cuál es la hipótesis nula y la hipótesis alternativa en una prueba de normalidad?

4.3 Si se desea verificar que los datos siguen una distribución normal, ¿qué rango de p-valores sería deseable?

4.4 ¿Qué muestra un gráfico Q-Q y cómo complementa a las pruebas formales de normalidad?

5. Relación entre variables (notebooks 09-12)

5.1 ¿Para qué se utiliza la prueba de Chi-cuadrado en tablas cruzadas?

5.2 ¿Cuál es la hipótesis nula y la hipótesis alternativa en una prueba de Chi-cuadrado?

5.3 ¿Cuáles son los principales requisitos o supuestos que deben cumplirse para aplicar la prueba de Chi-cuadrado en tablas de contingencia?

5.4 ¿La correlación entre dos variables implica una relación causal?

5.5 ¿Qué mide el coeficiente de correlación de Pearson y cómo se interpreta?

5.6 ¿Cuál es una alternativa no paramétrica al coeficiente de correlación de Pearson y en qué casos es preferible utilizarla?

5.7 ¿Qué significa obtener un p-valor menor a 0.05 en una prueba de hipótesis para la correlación entre dos variables?

5.8 ¿Para qué se utiliza el análisis de correspondencias en el análisis de datos?

5.9 En un análisis de correspondencias, ¿qué interpretación se les da a dos elementos con una distancia muy corta en el gráfico?

5.10 En un análisis de correspondencias, ¿qué significa que una categoría esté ubicada cerca del origen (centro) del gráfico?

6. Comparación de grupos (notebooks 14-15)

6.1 ¿Cuál es el propósito de las pruebas A/B en la toma de decisiones basadas en datos?

6.2 Al realizar una prueba A/B, ¿en qué situaciones es más apropiado usar una prueba z en lugar de una prueba t?

6.3 ¿Cuál es una alternativa no paramétrica a la prueba t?

6.4 ¿Qué tipo de variable debe ser la dependiente y qué tipo de variable debe ser la independiente en un ANOVA de un factor?

6.5 ¿Qué tipo de estadístico de prueba se utiliza en el análisis ANOVA?

6.6 ¿Cuál es la hipótesis nula y la hipótesis alternativa en una prueba de ANOVA?

6.7 ¿Cómo se interpreta un p-valor menor que 0.05 en el resultado de una prueba ANOVA?

6.8 ¿Por qué es necesario realizar pruebas post-hoc después de un ANOVA significativo?

6.9 Menciona algunos ejemplos de pruebas post-hoc.

6.10 ¿Cuáles son los supuestos que deben cumplirse para aplicar ANOVA correctamente?

6.11 ¿Para qué se utiliza la prueba de Levene en el contexto de ANOVA?

6.12 ¿Cuál es la alternativa no paramétrica a la prueba ANOVA y en qué situaciones es conveniente aplicarla?

7. Análisis de regresión (notebooks 16-18)

- 7.1 ¿En qué consiste el análisis de regresión?
- 7.2 ¿Qué tipo de variable (cuantitativa o cualitativa) debe ser la variable dependiente y qué tipo pueden ser las variables independientes en una regresión?
- 7.3 ¿Cómo se interpreta el coeficiente de determinación (R^2) y qué valores son considerados preferibles?
- 7.4 ¿Cómo se interpretan los coeficientes de regresión en un modelo de regresión lineal, cuando la variable independiente es cuantitativa?
- 7.5 Con un nivel de significancia del 5%, ¿a partir de qué p-valor se considera que una variable es estadísticamente significativa en un análisis de regresión?
- 7.6 ¿Cuál es la función de la tabla ANOVA en un análisis de regresión y qué información proporciona?
- 7.7 ¿Qué mide el estadístico Durbin-Watson y en qué contexto se utiliza en el análisis de regresión?
- 7.8 ¿Qué es la multicolinealidad en regresión y cómo puede afectar los resultados del modelo?
- 7.9 ¿Para qué se utilizan los valores del Factor de Inflación de la Varianza (VIF) en el análisis de regresión?
- 7.10 ¿Qué es la homocedasticidad y por qué es importante en la regresión lineal?
- 7.11 ¿Qué es una variable dicotómica y cómo se utiliza en un modelo de regresión?
- 7.12 De acuerdo con lo revisado en clase, ¿cuál es el tamaño muestral mínimo recomendado para realizar un análisis de regresión?
- 7.13 ¿Cómo se describe el método de eliminación hacia atrás en la selección de modelos de regresión?

8. Reducción de dimensiones: PCA y análisis factorial (notebooks 20 y 21)

- 8.1 ¿Qué diferencia conceptual hay entre el análisis de componentes principales (PCA) y el análisis factorial?
- 8.2 ¿Por qué es necesario estandarizar las variables antes de aplicar PCA?
- 8.3 ¿Qué criterios se utilizan para determinar el número de componentes o factores (criterio de Kaiser, gráfico de sedimentación)?
- 8.4 ¿Qué utilidad práctica tiene el análisis factorial en la reducción y comprensión de datos?
- 8.5 ¿Para qué se utiliza la prueba de esfericidad de Bartlett y qué valor es deseable para su significancia?
- 8.6 ¿Cuál es la técnica más utilizada para la extracción de factores en el análisis factorial exploratorio?
- 8.7 ¿Cuál es el método de rotación ortogonal más utilizado y en qué casos es preferible?
- 8.8 ¿Qué representan las comunalidades en el análisis factorial y cómo se interpretan?
- 8.9 ¿Qué representan las cargas factoriales y cuál es su importancia en la interpretación de los factores?
- 8.10 ¿Para qué sirve el alfa de Cronbach y cómo se interpreta?

9. Análisis de conglomerados (notebook 19)

- 9.1 ¿Por qué estandarizar variables es necesario antes de aplicar K-Means?

9.2 ¿Para qué se utiliza el análisis de conglomerados y en qué situaciones es útil?

9.3 ¿Cómo determinar el número óptimo de clusters?

9.4 ¿En qué escenarios es recomendable utilizar cada uno de los siguientes métodos de análisis de conglomerados?

- a. Jerárquico
- b. K-medias (K-means)

10. Integración y pensamiento crítico en la toma de decisiones (todo el curso)

10.1 ¿Cómo decidir qué técnica utilizar según el tipo de variable, objetivo del análisis y supuestos estadísticos?

10.2 ¿Qué diferencia hay entre significancia estadística y relevancia práctica?

10.3 ¿Cómo se conectan las pruebas de hipótesis, la regresión y el clustering para generar ventajas competitivas en una estrategia de negocios?

10.4 Una empresa quiere segmentar clientes usando 10 variables, ¿qué pasos seguirías desde la preparación hasta la validación del modelo?

10.5 Explica cómo combinarías regresión y clustering en una estrategia de negocios.

10.6 ¿En qué escenarios un modelo estadísticamente correcto puede llevar a una mala decisión de negocio y por qué?